



VK Practice: Предсказание Пола Пользователей

Применение машинного обучения
для точного таргетинга рекламы

Выполнил Шваров Роман

Цель Проекта и Бизнес-Ценность

Проект направлен на предсказание пола пользователей социальных сетей на основе логов показов рекламы. Это имеет критическое значение для VK Ads, поскольку позволяет значительно повысить точность таргетинга рекламных кампаний, например, подарочных наборов.

1

Улучшенный CTR

Более релевантная реклама привлекает больше внимания.

2

Рост Конверсии

Выше вероятность совершения целевого действия.

3

Оптимизация Бюджета

Снижение затрат на нецелевые показы.

Пайплайн Решения: От Данных к Предсказанию

01

Загрузка и Обогащение

Загрузка CSV, объединение с `referer_vectors`, `geo_info`, парсинг `user_agent` и расчет временных меток.

03

Агрегация до User-level

Консолидация всех данных в одну строку на пользователя.

05

Кросс-валидация

5-кратная стратифицированная кросс-валидация с OOF-предсказаниями и подбором порога по F1.

02

Feature Engineering

Генерация поведенческих признаков: доли активности по времени, частоты, энтропии, сессии, `resency`, агрегаты.

04

Моделирование с CatBoost

Использование градиентного бустинга для построения надежной предсказательной модели.

06

Инференс и Сабмит

Обучение финальной модели на всей обучающей выборке и генерация файла `submission.csv` для тестовых пользователей.

Модель: CatBoost для Точных Предсказаний

CatBoostClassifier — мощный ансамбль из неглубоких деревьев решений, который отлично подходит для данной задачи благодаря своей способности работать с категориальными признаками напрямую и устойчивости к шуму.



Градиентный Бустинг

Деревья строятся последовательно, исправляя ошибки предыдущих моделей.



Нелинейности и Взаимодействия

Улавливает сложные паттерны в данных, в отличие от линейных моделей.



Прямая Обработка Категорий

Берёт категориальные признаки напрямую, что снижает утечки данных.



Робастность и Стабильность

Устойчив к шуму, выбросам и не требует масштабирования признаков.

Почему CatBoost превосходит Линейные Модели

- **Нелинейные Паттерны:**
Взаимодействия типа «часть суток × тип устройства × страна» улавливаются CatBoost, но труднодоступны для линейных моделей.
- **Категориальные Признаки:**
CatBoost корректно кодирует и упорядочивает их, избегая проблем, свойственных One-Hot Encoding или Label Encoding в линейных моделях.
- **Робастность:** Модель устойчива к шумным и коррелированным признакам, не требуя предварительной нормализации или стандартизации данных.
- **Практическая Эффективность:**
На наших данных переход от логистической регрессии к CatBoost показал заметное улучшение метрик, таких как AUC.



Честная Оценка: Кросс-Валидация

Для получения объективной оценки качества модели и предотвращения переобучения используется строгую процедуру кросс-валидации.

5-Fold Stratified K-Fold

Данные делятся на 5 частей с сохранением распределения классов. Модель обучается на 4 фолдах, тестируется на одном отложенном.

OOF-Предсказания


Собираются предсказания для каждого пользователя, сделанные моделью, которая "не видела" его во время обучения. Это гарантирует честность метрик.

Подбор Порога по F1

Оптимальный порог классификации (у нас ≈ 0.44) подбирается на OOF-предсказаниях для максимизации метрики F1.

Сводные Метрики

Финальные метрики (AUC, F1, Accuracy) рассчитываются на всех OOF-предсказаниях, что дает надежную оценку производительности.



Визуальные данные


Доли событий ночью/утром/днём/вечером

train.scv




Кривая сильно выше диагонали, отличная разделимость

train.csv + referer_vectors.csv + geo_info.csv




Кривая высоко, хорошая точность

train.csv + referer_vectors.csv + geo_info.csv



Большинство предсказаний верны

train_labels.csv (свои данные для дополнительного теста модели)



Статистика CV(OOF)

CV результаты неплохие, однако на учебных данных модель ведёт себя точнее

- F1: 0.684 — неплохой баланс между точностью и полнотой
- AUC: 0.734 — модель хорошо разделяет классы по вероятности.
- Accuracy: 61% - неплохая точность

Итоги

Решение обеспечивает значительную бизнес-ценность и имеет большой потенциал для дальнейшего развития

Планы на Будущее



Тюнинг CatBoost

Исследование регуляризации, grow_policy, border_count и глубины для дальнейшей оптимизации.



Блендинг/Стэкинг Моделей

Комбинирование CatBoost с LightGBM и логистической регрессией для повышения надежности.



Текстовые Признаки

Использование TF-IDF и эмбедингов для анализа текстовых данных из referer path.



Semi-Supervised Обучение

Применение псевдометок на тестовой выборке для использования неразмеченных данных.